


林呈恩

1. 請推導 FP64 的 10 進位數字大小範圍。(15+15)

$$\text{約小: } 1.0 \times 2^{-1022} = 10^{-307} \quad x = -1022 \log 2 \approx -307.6527 \quad 10^{-307} \times 10^{-0.6527} \approx 2.2 \times 10^{-308}$$

$$\text{約大: } 2.0 \times 2^{1023} = 2^{1024} = 10^8 \quad y = 1024 \log 2 \approx 308.2547 \quad 10^{308.2547} = 10^{308} \times 10^{0.2547} \approx 1.8 \times 10^{308}$$

2. 請以 FP32, BFP16 格式表示數字 0.6, 使用 BFP16 求得的結果, 與原始數值的誤差有多少?

(20+20+20) 0.6

$$\begin{array}{r} 1.2 - 1 \\ 0.4 - 0 \\ 0.8 - 0 \\ 1.6 - 1 \\ \hline 1.2 - 1 \end{array}$$

0.6 = 0.1001 1001 ...

-1 + 127 = 126

= 1.001 1001 ... $\times 2^{-1}$

	S	E	F
FP32:	0	01111110	001 1001 1001 1001 1001 1001

BFP16:	0	01111110	001 1001
--------	---	----------	----------

$$1.0011001 \times 2^{-1} \approx 0.597656$$

誤差約: $0.6 - 0.597656 = 0.002344$

3. 以單精準度 FP32 計算(請詳列使用二進位之計算過程與最終結果, 包括標準浮點數格式)

56.25 * 3.75 與 56.25 + 3.75 (30+50)

$$(1) 111000.01 \times 1.11 = 1.1100001 \times 2^5 \times 1.111 \times 2^1 = 1.0100101111 \times 2^6$$

$$\begin{array}{r} 1.1100001 \\ 1.1110000 \\ \hline \end{array}$$

$$= 1.0100101111 \times 2^7 \quad 7 + 127 = 134 = 128 + 6$$

	S	E	F
FP32:	0	10000110	101001011110000000000000

$$(2) 1.1100001 \times 2^5 + 1.111 \times 2^1 = 1.1100001 \times 2^5 + 0.0001111 \times 2^5$$

$$\begin{array}{r} 1.1100001 \\ 0.0001111 \\ \hline 1.1110000 \end{array}$$

$$= 1.111 \times 2^5$$

3 + 127 = 132 = 128 + 4

	S	E	F
FP32:	0	10000100	111000000000000000000000

4. 你對本章所教授的內容有任何學習心得、疑問困難、意見或建議? (10*3)

這章節比起前二章還有趣, 有計算也有背的部分, 計算也不會太難, 只要小心不要計算錯。

稍微困難的是乘法、除法, 分別有兩種方法, 共四種, 規則都不一樣時常搞混。

抄在白板的字有黑點, 坐後面看不清楚, 甚至投影機沒關, 字在投影的地方更不清楚。